42

崩溃一致性：FSCK 和日志

我们已经看到，文件系统（file system）管理着一组数据结构（data structure），用来实现人们所期望的那些抽象（abstraction）：文件、目录（directory），以及支撑文件系统基本抽象所需的其他所有元数据（metadata）。和大多数数据结构——比如运行中的程序（running program）在内存里的那些——不同，文件系统的数据结构必须**持久**（persist），也就是说，它们必须长期保存下来，存放在断电（power loss）后也不会丢失数据的设备上（比如硬盘或基于闪存（flash）的 SSD）。

文件系统面临的一大挑战是：在可能发生**断电**（power loss）或**系统崩溃**（system crash）的情况下，如何更新持久的数据结构。具体来说，如果正当磁盘上的结构更新到一半时，有人被电源线绊了一下，机器断电了，会怎样？或者操作系统遇到 bug 崩溃了，又会怎样？由于断电和崩溃的存在，更新持久数据结构可能相当棘手，这就引出了文件系统实现中一个有趣的新问题，叫作**崩溃一致性问题**（crash-consistency problem）。

这个问题很容易理解。假设为了完成某个操作，你必须更新磁盘上的两个结构 A 和 B。由于磁盘一次只处理一个请求，两个请求中总有一个先到达磁盘（A 或 B）。如果系统在其中一个写入完成后崩溃或断电，磁盘上的结构就会处于**不一致**（inconsistent）的状态。于是，我们遇到了一个所有文件系统都必须解决的问题：

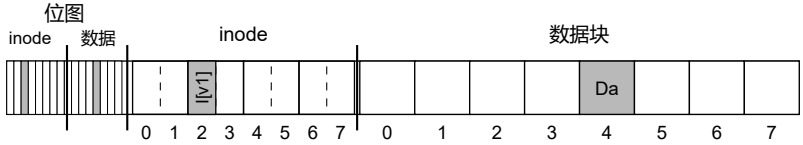
> 关键问题：如何在可能崩溃的情况下更新磁盘
> 系统可能在任意两次写入之间崩溃或断电，因此磁盘上的状态可能只更新了一部分。崩溃之后，系统重新启动，并希望再次挂载（mount）文件系统（以便访问文件等）。既然崩溃可能发生在任意时刻，我们如何确保文件系统让磁盘上的映像保持在合理的状态？

在本章中，我们会更详细地描述这个问题，并看看文件系统用过哪些方法来解决它。我们先研究较老的文件系统采用的方法，叫作 **fsck**，即**文件系统检查程序**（file system checker）。然后我们转向另一种方法，叫作**日志**（journaling），也叫**预写日志**（write-ahead logging）。这种技术会给每次写入增加一点开销，但能更快地从崩溃或断电中恢复。我们会讨论日志的基本机制，包括 Linux ext3 [T98, PAA05]（一个比较现代的日志文件系统（journaling file system））实现的几种不同的日志方式。

42.1 一个详细的例子

为了开始研究日志，我们先来看一个例子。我们需要一个会以某种方式更新磁盘结构的**工作负载**（workload）。这里假设工作负载很简单：往一个已有的文件末尾追加一个数据块（data block）。追加的过程是：打开文件，调用 `lseek()` 把文件偏移量（file offset）移到文件末尾，然后向文件发出一次 4 KB 的写入，最后关闭文件。

我们再假设磁盘上使用的是标准的简单文件系统结构，和我们之前见过的文件系统类似。这个小例子包括一个 **inode 位图**（inode bitmap，只有 8 位，每个 inode 一位）、一个**数据位图**（data bitmap，也是 8 位，每个数据块一位）、inode（共 8 个，编号 0 到 7，分布在四个块中），以及数据块（共 8 个，编号 0 到 7）。下面是这个文件系统的示意图：



从图中的结构可以看出，系统分配了一个 inode，其 inode 号（inode number）为 2，它在 inode 位图中做了标记；还分配了一个数据块（数据块 4），它也在数据位图（data bitmap）中做了标记。这个 inode 记作 I[v1]，因为它是这个 inode 的第一个版本；它很快就会被更新（因为上面描述的工作负载）。

我们也来看看这个简化的 inode 内部。I[v1] 里面是这样的：

```
owner       : remzi
permissions : read-write
size        : 1
pointer     : 4
pointer     : null
pointer     : null
pointer     : null
```

在这个简化的 inode 中，文件的 `size` 是 1（分配了一个块），第一个直接指针（direct pointer）指向块 `4`（文件的第一个数据块 Da），另外三个直接指针都设为 `null`（表示没有使用）。当然，真实的 inode 有多得多的字段；更多信息请参阅前面几章。

往文件里追加数据，就是给它加一个新的数据块，因此必须更新磁盘上的三个结构：inode（它必须指向新块，并且因为追加而记录新的、更大的文件大小）、新的数据块 Db，以及新版本的数据位图（记作 B[v2]），用来表示新数据块已经分配出去了。

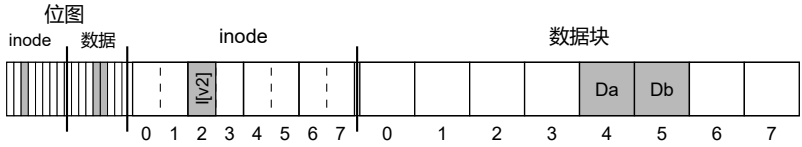
所以，在系统内存中，我们有三个块（block）必须写到磁盘上。更新后的 inode（inode 版本 2，简称 I[v2]）现在是这样的：

```
owner       : remzi
permissions : read-write
size        : 2
pointer     : 4
pointer     : 5
```

```
pointer      : null
pointer      : null
```

更新后的数据位图（data bitmap）B[v2] 现在是这样的：00001100。最后是数据块（Db），里面装的就是用户放进文件里的任何东西。也许是偷来的音乐?

我们希望文件系统最终在磁盘上的映像是这样的：



为了完成这一转变，文件系统必须对磁盘执行三次独立的写入，inode（I[v2]）、位图（B[v2]）和数据块（Db）各一次。注意，用户发出 `write()` 系统调用（system call）时，这些写入通常不会立即发生；脏的 inode、位图（bitmap）和新数据会先在内存（**页缓存**，page cache，或**缓冲区缓存**，buffer cache）中待上一段时间；然后，当文件系统最终决定把它们写到磁盘时（比如 5 秒或 30 秒之后），文件系统才会向磁盘发出所需的写请求。遗憾的是，崩溃可能会发生，打断这些磁盘更新。特别是，如果崩溃发生在这些写入完成了一两个、但没有全部完成之后，文件系统就可能处于一种奇怪的状态。

崩溃场景

为了更好地理解这个问题，我们来看几个崩溃场景的例子。假设只有一次写入成功了；那么有三种可能的结果，列举如下：

- **只有数据块（Db）写到了磁盘上**。在这种情况下，数据在磁盘上，但没有 inode 指向它，也没有位图表示这个块已被分配。因此，这就好像那次写入从未发生过一样。从文件系统崩溃一致性（crash consistency）的角度看，这种情况根本不是问题[1]。
- **只有更新后的 inode（I[v2]）写到了磁盘上**。在这种情况下，inode 指向了 Db 本该写入的磁盘地址（5），但 Db 还没有写到那里。因此，如果我们相信这个指针，就会从磁盘上读到**垃圾**（garbage）数据（磁盘地址（disk address）5 原来的内容）。
  此外，我们还遇到了一个新问题，叫作**文件系统不一致**（file-system inconsistency）。磁盘上的位图告诉我们数据块 5 还没有被分配，inode 却说它已经分配了。位图和 inode 之间的这种矛盾，就是文件系统数据结构中的不一致；要使用这个文件系统，我们必须设法解决这个问题（下文会详细讨论）。
- **只有更新后的位图（B[v2]）写到了磁盘上**。在这种情况下，位图表示块 5 已被分配，但没有 inode 指向它。因此，文件系统又一次不一致了；如果不加处理，这次写入会造成 **space leak**（空间泄漏），因为文件系统永远不会再使用块 5。

在这次向磁盘写入三个块的尝试中，还有另外三种崩溃场景。在这些情况下，两次写入成功了，最后一次失败了：

[1]不过，这对用户来说可能是个问题：用户刚刚丢了一些数据！

- **inode（I[v2]）和位图（B[v2]）写到了磁盘上，但数据（Db）没有**。在这种情况下，文件系统的元数据是完全一致的：inode 有一个指向块 5 的指针，位图表示块 5 正在使用，所以从文件系统元数据的角度看，一切正常。但有一个问题：块 5 里又是垃圾。
- **inode（I[v2]）和数据块（Db）写到了磁盘上，但位图（B[v2]）没有**。在这种情况下，inode 指向了磁盘上正确的数据，但 inode 和旧版本的位图（B1）之间又出现了不一致。因此，我们还是得先解决这个问题，才能使用文件系统。
- **位图（B[v2]）和数据块（Db）写到了磁盘上，但 inode（I[v2]）没有**。在这种情况下，inode 和数据位图（data bitmap）之间又出现了不一致。不过，虽然这个块已经写入、位图也表明它在使用中，我们却不知道它属于哪个文件，因为没有任何 inode 指向这个文件。

崩溃一致性问题

从这些崩溃场景中，希望你能看出，崩溃会给磁盘上的文件系统映像带来许多问题：文件系统数据结构可能不一致；可能出现 space leak；可能把垃圾数据返回给用户；等等。理想情况下，我们希望**原子地**（atomically）把文件系统从一个一致的状态（例如，文件追加之前）转移到另一个一致的状态（例如，inode、位图和新数据块都写到磁盘之后）。遗憾的是，这一点不容易做到，因为磁盘一次只提交一个写入，而这些更新之间可能发生崩溃或断电。我们把这个一般性的问题称为**崩溃一致性问题**（也可以叫它 **consistent-update problem**）。

42.2 方案一：文件系统检查程序

早期的文件系统对崩溃一致性（crash consistency）采取了一种简单的方法。基本上，它们决定先让不一致发生，以后（重启时）再修复。这种“偷懒”做法的一个经典例子，就是做这件事的工具：**fsck**[2]。fsck 是一个 UNIX 工具，用来找出这类不一致并加以修复 [MK96]；不同的系统上也有类似的工具，用来检查和修复磁盘分区。注意，这种方法并不能解决所有问题；比如上面那种情况：文件系统看起来是一致的，但 inode 指向了垃圾数据。它真正的目标只是确保文件系统的元数据在内部是一致的。

正如 McKusick 和 Kowalski 的论文 [MK96] 所总结的，fsck 工具分几个阶段运行。它在文件系统挂载、可供使用之前运行（fsck 假定它运行时没有其他文件系统活动在进行）；运行结束后，磁盘上的文件系统应该是一致的，因此可以开放给用户访问。

下面是 fsck 所做工作的基本概述：

- **超级块：** fsck 首先检查超级块（superblock）看起来是否合理，主要是做一些健全性检查，比如确保文件系统的大小大于已分配的块数。这些健全性检查的目的通常是找出可疑的（损坏的）超级块；在这种情况下，系统（或管理员）可能会决定改用超级块的某个备份副本。
- **空闲块：** 接下来，fsck 扫描 inode、间接块（indirect block）、二级间接块（double indirect block）等，从而弄清楚文件系统中当前有哪些块已被分配。它利用这些信息

[2] 读作“eff-ess-see-kay”或“eff-ess-check”；如果你不喜欢这个工具，也可以读作“eff-suck”（suck 意为“烂透了”）。没错，严肃的专业人士也用这个说法。

生成一份正确的分配位图；因此，如果位图和 inode 之间有任何不一致，都以 inode 中的信息为准来解决。对所有 inode 也做同样的检查，确保所有看起来正在使用的 inode 都在 inode 位图中做了相应标记。

- **inode 状态：** 检查每个 inode 有没有损坏或其他问题。例如，fsck 会确保每个已分配的 inode 都有一个有效的类型字段（例如普通文件、目录、符号链接（symbolic link）等）。如果 inode 的字段有不易修复的问题，这个 inode 就会被视为可疑的，并被 fsck 清除；inode 位图也会相应更新。
- **inode 链接：** fsck 还会核对每个已分配 inode 的链接计数（link count）。你可能还记得，链接计数（link count）表示有多少个不同的目录包含对这个文件的引用（即链接）。为了核对链接计数（link count），fsck 从根目录（root directory）开始扫描整个目录树（directory tree），为文件系统中的每个文件和目录自己算出一份链接计数。如果新算出的计数和 inode 中记录的不一致，就必须采取纠正措施，通常是修正 inode 中的计数。如果发现了一个已分配的 inode，却没有任何目录引用它，就把它移到 `lost+found` 目录中。
- **重复：** fsck 还会检查重复的指针，即两个不同的 inode 指向同一个块的情况。如果其中一个 inode 明显是坏的，就可以把它清除。另外，也可以把被指向的块复制一份，按需让每个 inode 都有自己的副本。
- **坏块：** 扫描所有指针的列表时，还会检查坏块指针（bad block pointer）。如果一个指针明显指向了有效范围之外的东西，例如它的地址指向的块大于分区的大小，这个指针就被认为是“坏”的。在这种情况下，fsck 做不了什么太聪明的事；它只是把这个指针从 inode 或间接块（indirect block）中删掉（清除）。
- **目录检查：** fsck 并不理解用户文件的内容；但目录里存放的是由文件系统自己创建的、格式特定的信息。因此，fsck 会对每个目录的内容做额外的完整性（integrity）检查，确保“.”和“..”是最前面的两个目录项（directory entry），确保目录项中引用的每个 inode 都已分配，并确保在整个层次结构中，任何目录都只被链接一次。

可以看出，要构建一个能用的 fsck，需要对文件系统有非常细致的了解；确保这样一段代码在所有情况下都能正确工作，可能相当有挑战性 [G+08]。然而，fsck（以及类似的方法）还有一个更大、或许也更根本的问题：它们太慢了。如果磁盘卷（disk volume）非常大，扫描整个磁盘来找出所有已分配的块、读取整个目录树，可能要花好几分钟甚至几个小时。随着磁盘容量增长、RAID 越来越普及，fsck 的性能变得让人无法接受（尽管最近有一些进展 [M+13]）。

从更高的层面看，fsck 的基本前提似乎有点不合情理。想想上面的例子，只有三个块要写到磁盘上；为了修复仅仅更新三个块时出现的问题，却要扫描整个磁盘，代价高得离谱。这种情况就好比你把钥匙掉在了卧室的地板上，然后启动一个把整栋房子翻个遍找钥匙的恢复算法，从地下室开始，一个房间一个房间地找过去。这样做能找到，但太浪费了。因此，随着磁盘（和 RAID）越来越大，研究人员和从业者开始寻找其他解决方案。

42.3 方案二：日志（或预写日志）

consistent-update problem 最流行的解法，大概借鉴自数据库管理系统（database management system）领域的一个思想。这个思想叫作**预写日志**（write-ahead logging），正是为了解决这类问题而发明的。在文件系统中，由于历史原因，我们通常把预写日志（write-ahead logging）叫作**日志**（journaling）。第一个这样做的文件系统是 Cedar [H87]，不过如今许多现代文件系统都用了这个思想，包括 Linux ext3 和 ext4、reiserfs、IBM 的 JFS、SGI 的 XFS 以及 Windows NTFS。

基本思想如下。更新磁盘时，在原地覆盖那些结构之前，先写下一条小小的记录（写在磁盘上的另一个地方，一个大家都知道的位置），描述你接下来要做什么。写这条记录就是“预写”（write ahead）的部分，而我们把它写到一个组织成“日志”（log）的结构里；于是就有了“预写日志”（write-ahead logging）这个名字。

把这条记录写到磁盘上，就能保证：如果在更新（覆盖）结构的过程中发生了崩溃，你可以回过头去看看你写下的记录，然后再试一次；这样一来，崩溃之后你就能确切地知道要修复什么（以及怎么修复），而不必扫描整个磁盘。因此，日志在设计上就是在更新时多做一点工作，来大大减少恢复时需要做的工作。

下面我们来描述 **Linux ext3** 这个流行的日志文件系统（journaling file system）是如何把日志纳入文件系统的。它在磁盘上的大部分结构都和 **Linux ext2** 相同，例如，磁盘被划分为若干块组，每个块组（block group）包含一个 inode 位图、一个数据位图（data bitmap）、若干 inode 和数据块。新增的关键结构就是日志本身，它在分区内或另一个设备上占据一小块空间。因此，一个（没有日志的）ext2 文件系统看起来是这样的：



假设日志放在同一个文件系统映像中（不过有时它也放在单独的设备上，或者作为文件系统中的一个文件），带日志的 ext3 文件系统看起来是这样的：

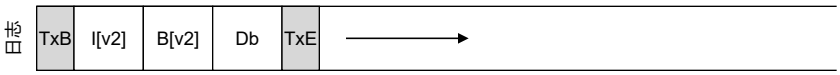


真正的区别只是多了一个日志，当然，还有它的用法。

数据日志

我们来看一个简单的例子，以理解**数据日志**（data journaling）是怎样工作的。数据日志（data journaling）是 Linux ext3 文件系统提供的一种模式，下面的讨论大多以它为基础。

假设我们又要做那个典型的更新：把 inode（I[v2]）、位图（B[v2]）和数据块（Db）写到磁盘上。现在，在把它们写到磁盘上的最终位置之前，我们要先把它们写到日志（log，也叫 journal）里。在日志中，它看起来是这样的：



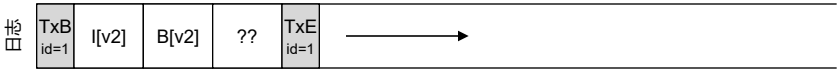
可以看到，这里我们写了五个块。事务开始块（transaction begin block，TxB）告诉我们这次更新的情况，包括对文件系统即将进行的更新的信息（例如，块 I[v2]、B[v2] 和 Db 的最终地址），以及某种**事务标识符**（transaction identifier，**TID**）。中间三个块就是这些块本身的确切内容；这叫作**物理日志**（physical logging），因为我们把更新的确切物理内容放进了日志（另一种思路是**逻辑日志**（logical logging），它把更新的一种更紧凑的逻辑表示放进日志，例如“这次更新要把数据块 Db 追加到文件 X”，这种方式复杂一些，但能节省日志空间，或许还能提高性能）。最后一个块（TxE）标志着这个事务（transaction）的结束，其中也包含 TID。

一旦这个事务安全地写到了磁盘上，我们就可以去覆盖文件系统中的旧结构了；这个过程叫作**检查点**（checkpointing）。因此，要对文件系统做**检查点**（checkpoint），也就是让它和日志中待完成的更新保持一致，我们就把 I[v2]、B[v2] 和 Db 写到上面看到的它们在磁盘上的位置；如果这些写入成功完成，我们就成功地对文件系统做了检查点（checkpoint），基本上就大功告成了。于是，我们最初的操作顺序是：

1. **日志写入：**把事务写入日志，包括一个事务开始块（transaction begin block）、所有待完成的数据和元数据更新，以及一个事务结束块（transaction end block）；等待这些写入完成。
2. **检查点：**把待完成的元数据和数据更新写到它们在文件系统中的最终位置。

在我们的例子中，我们会先把 TxB、I[v2]、B[v2]、Db 和 TxE 写到日志里。这些写入完成后，再通过检查点（checkpoint）把 I[v2]、B[v2] 和 Db 写到它们在磁盘上的最终位置，从而完成这次更新。

如果在写日志的过程中发生了崩溃，事情就有点棘手了。这里我们要把事务中的一组块（例如 TxB、I[v2]、B[v2]、Db、TxE）写到磁盘上。一种简单的办法是一次发出一个写入，等它完成后再发出下一个。但这样太慢了。理想情况下，我们希望一次发出全部五个块的写入，这样就能把五次写入变成一次顺序写入，速度更快。然而，这样做并不安全，原因如下：面对这样一次大的写入，磁盘内部可能会进行调度，以任意顺序完成这次大写入的各个小部分。因此，磁盘内部可能会（1）先写入 TxB、I[v2]、B[v2] 和 TxE，过一会儿才（2）写入 Db。遗憾的是，如果磁盘在（1）和（2）之间断电，磁盘上最终会是这样：



为什么这是个问题？嗯，这个事务看起来是一个有效的事务（它有开始块和结束块，而且序号相互匹配）。此外，文件系统没法看一眼第四个块就知道它是错的；毕竟，那是任意的用户数据。因此，如果系统现在重启并运行恢复，它就会重放（replay）这个事务，稀里糊涂地把垃圾块“??”的内容复制到 Db 本该存放的位置。对于文件里的任意用户数据，这

补充：强制写入磁盘

为了在两次磁盘写入之间强制规定顺序，现代文件系统必须采取一些额外的预防措施。在过去，要在两次写入 *A* 和 *B* 之间强制规定顺序很容易：只要向磁盘发出 *A* 的写入，等磁盘在写入完成时中断（interrupt）操作系统，然后再发出 *B* 的写入。

由于磁盘内部越来越多地使用写缓存（write cache），事情变得稍微复杂了一些。启用写缓冲（有时叫作 **immediate reporting**）后，磁盘只要把数据放进自己的内存缓存（cache），还没有真正写到磁盘上，就会告诉操作系统写入已经完成。如果操作系统接着发出后续的写入，就无法保证它会在前面的写入之后到达磁盘；因此，写入之间的顺序得不到保证。一种解决办法是禁用写缓冲（write buffering）。然而，更现代的系统会采取额外的预防措施，发出显式的**写屏障**（write barrier）；这样的屏障（barrier）完成时，能保证在屏障之前发出的所有写入，都会先于屏障之后发出的任何写入到达磁盘。

所有这些机制都要求我们非常信任磁盘能正确运行。遗憾的是，最近的研究表明，有些磁盘制造商为了交付“性能更高”的磁盘，明确地忽略写屏障（write barrier）请求，从而让磁盘看起来跑得更快，代价是有可能运行出错 [C+13, R+11]。正如 Kahan 所说，快的几乎总能打败慢的，哪怕快的是错的。

已经很糟糕了；如果这种事发生在文件系统的某个关键部分上，比如超级块，那就更糟了，文件系统可能因此无法挂载。

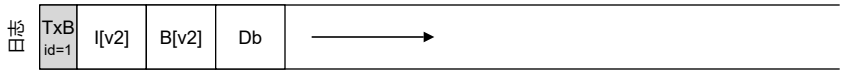
补充：优化日志写入

你可能已经注意到，写日志有一个特别低效的地方：文件系统必须先写出事务开始块（transaction begin block）和事务的内容；只有在这些写入完成之后，文件系统才能把事务结束块（transaction end block）发往磁盘。想想磁盘的工作原理，性能上的影响就很清楚了：通常会多花一圈旋转的时间（想想为什么）。

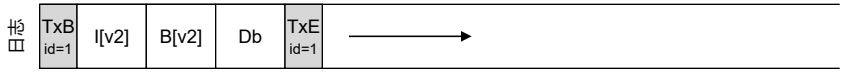
我们以前的一位研究生 Vijayan Prabhakaran 想出了一个简单的办法来解决这个问题 [P+05]。把事务写入日志时，在开始块（begin block）和结束块（end block）里加上日志内容的校验和（checksum）。这样一来，文件系统就可以一次写出整个事务，而不必等待；如果在恢复过程中，文件系统发现计算出的校验和（computed checksum）与事务中保存的校验和不一致，就可以断定崩溃发生在写入这个事务的过程中，从而丢弃这次文件系统更新。因此，只需对写入协议（protocol）和恢复系统稍作调整，文件系统就能在常见情况（common case）下获得更好的性能；除此之外，系统也更可靠了一点，因为现在从日志读出的任何内容都有校验和保护。

这个简单的修复很有吸引力，引起了 Linux 文件系统开发者的注意，他们随后把它纳入了下一代 Linux 文件系统，叫作（你猜对了！）**Linux ext4**。它现在运行在全世界数以百万计的机器上，包括 Android 手持平台。因此，在许多基于 Linux 的系统上，每当你向磁盘写入数据时，都有一小段在威斯康星开发的代码让你的系统变得更快、更可靠一点。

为了避免这个问题，文件系统分两步发出事务写入。首先，它把除 TxE 块之外的所有块写入日志，这些写入一次全部发出。这些写入完成后，日志看起来是这样的（还是假设我们的追加工作负载）：



这些写入完成后，文件系统再发出 TxE 块的写入，使日志处于最终的安全状态：



这个过程的一个重要方面是磁盘提供的原子性（atomicity）保证。事实证明，磁盘能保证任何 512 字节的写入要么完成，要么不发生（绝不会只写一半）；因此，为了确保 TxE 的写入是原子的，应该让它只占一个 512 字节的块。于是，我们目前更新文件系统的协议如下，三个阶段各有标注：

1. **日志写入：** 把事务的内容（包括 TxB、元数据和数据）写入日志；等待这些写入完成。
2. **日志提交：** 把事务提交块（transaction commit block，包含 TxE）写入日志；等待写入完成；此时称事务已**提交**（committed）。
3. **检查点：** 把更新的内容（元数据和数据）写到它们在磁盘上的最终位置。

恢复

现在我们来理解文件系统如何利用日志的内容从崩溃中**恢复**（recover）。在这一系列更新中，崩溃随时可能发生。如果崩溃发生在事务安全地写入日志之前（即上面的第 2 步完成之前），我们的工作就很简单：直接跳过这次待完成的更新。如果崩溃发生在事务已经提交到日志之后、检查点（checkpoint）完成之前，文件系统可以按如下方式**恢复**这次更新。系统启动时，文件系统的恢复过程会扫描日志，找出已经提交到磁盘的事务；然后（按顺序）**重放**（replay）这些事务，文件系统再次尝试把事务中的块写到它们在磁盘上的最终位置。这种形式的日志是最简单的形式之一，叫作**重做日志**（redo logging）。通过恢复日志中已提交的事务，文件系统确保磁盘上的结构是一致的，然后就可以继续挂载文件系统，准备处理新的请求了。

注意，在检查点（checkpoint）过程中的任何时刻发生崩溃都没有关系，即使有些块已经更新到了最终位置也无妨。最坏的情况是，其中一些更新在恢复时会再执行一遍。由于恢复是一种罕见的操作（只在系统意外崩溃之后才进行），多出几次冗余写入不值得担心[3]。

[3]除非你什么都担心，那我们也帮不了你。别这么操心了，这对健康不好！不过现在你大概又开始担心自己操心过度了。

批量更新日志

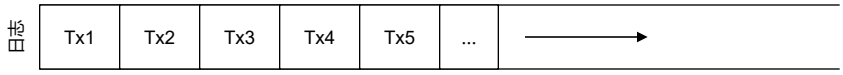
你可能已经注意到，这个基本协议可能会增加大量额外的磁盘流量。例如，假设我们在同一个目录里连续创建两个文件，分别叫作 `file1` 和 `file2`。创建一个文件，就要更新磁盘上的一些结构，至少包括：inode 位图（分配一个新 inode）、新创建的文件的 inode、父目录（parent directory）中包含新目录项的数据块，以及父目录的 inode（它现在有了新的修改时间）。有了日志，对于这两次文件创建，我们在逻辑上都要把所有这些信息提交到日志；由于这两个文件在同一个目录中，再假设它们的 inode 甚至在同一个 inode 块（inode block）里，这就意味着，如果不加注意，我们就会一遍又一遍地写同样的这些块。

为了解决这个问题，有些文件系统（例如 Linux ext3）不会把每次更新一个一个地提交到磁盘；而是把所有更新缓冲到一个全局事务中。在上面的例子中，创建这两个文件时，文件系统只是把内存中的 inode 位图、文件的 inode、目录数据和目录 inode 标记为脏，并把它们加到构成当前事务的块列表中。等到最终该把这些块写到磁盘时（比如 5 秒超时（timeout）之后），就提交这个包含上述所有更新的全局事务。因此，通过缓冲更新，文件系统在许多情况下都能避免向磁盘写入过多的数据。

让日志大小有限

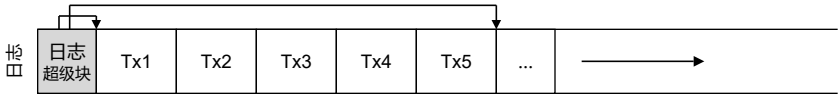
至此，我们得到了一个更新文件系统磁盘结构的基本协议。文件系统先把更新在内存中缓冲一段时间；等到最终该写入磁盘时，文件系统先小心地把事务的细节写到日志（也就是预写日志（write-ahead logging））中；事务完成后，文件系统再通过检查点（checkpoint）把这些块写到它们在磁盘上的最终位置。

然而，日志的大小是有限的。如果我们不停地往里面添加事务（就像下图这样），它很快就会被填满。你觉得那时会发生什么？



日志被填满时，会出现两个问题。第一个比较简单，但不那么要紧：日志越大，恢复所需的时间就越长，因为恢复过程必须（按顺序）重放（replay）日志中的所有事务才能恢复。第二个问题更严重：日志满了（或者快满了）时，就再也不能向磁盘提交新的事务了，文件系统也就变得“不太有用”（也就是没用了）。

为了解决这些问题，日志文件系统（journaling file system）把日志当作一个循环数据结构，一遍又一遍地重复使用它；这就是日志有时也被叫作**循环日志**（circular log）的原因。为此，文件系统必须在检查点（checkpoint）之后的某个时候采取行动。具体来说，一旦某个事务完成了检查点（checkpoint），文件系统就应该释放它在日志中占用的空间，让这些日志空间可以重新使用。实现这一目标的方法有很多；例如，你可以简单地在一个**日志超级块**（journal superblock）中标记出日志中最老的和最新的尚未完成检查点（checkpoint）的事务；其余空间都是空闲的。下面是图示：



在日志超级块（journal superblock）中（不要和文件系统主超级块混淆），日志系统记录足够的信息，以便知道哪些事务还没有完成检查点（checkpoint），从而既缩短了恢复时间，又能让日志以循环的方式重复使用。于是，我们在基本协议中又加了一步：

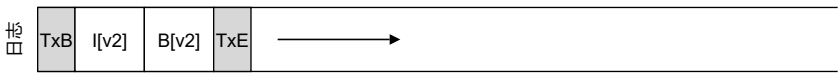
1. **日志写入：**把事务的内容（包含 TxB 和更新的内容）写入日志；等待这些写入完成。
2. **日志提交：**把事务提交块（transaction commit block，包含 TxE）写入日志；等待写入完成；事务现在已**提交**。
3. **检查点：**把更新的内容写到它们在文件系统中的最终位置。
4. **释放：**过一段时间后，通过更新日志超级块（journal superblock），在日志中把这个事务标记为空闲。

这样，我们就得到了最终的数据日志（data journaling）协议。但还有一个问题：我们把每个数据块都向磁盘写了两次，这是一笔沉重的代价，尤其是为了系统崩溃这样罕见的事情。你能想出一种不用把数据写两次、又能保持一致性的办法吗?

元数据日志

虽然恢复现在很快了（扫描日志并重放几个事务，而不是扫描整个磁盘），但文件系统的正常运行比我们希望的要慢。特别是，每次写入磁盘时，我们现在还要先写日志，写入流量因此翻了一倍；在顺序写的工作负载中，这种翻倍尤其让人头疼，因为写入现在只能以驱动器峰值写入带宽（bandwidth）的一半进行。此外，在写日志和写主文件系统之间，还有一次代价高昂的寻道（seek），这在某些工作负载下会带来明显的开销。

由于把每个数据块都向磁盘写两次的代价很高，人们尝试了几种不同的办法来提升性能。例如，我们上面描述的日志模式通常叫作**数据日志**（data journaling，如 Linux ext3 中的叫法），因为它把所有用户数据（以及文件系统的元数据）都记入了日志。一种更简单（也更常见）的日志形式有时叫作**有序日志**（ordered journaling，或者就叫**元数据日志**，metadata journaling），它和数据日志（data journaling）几乎一样，只是用户数据不写入日志。因此，执行和上面一样的更新时，写入日志的是下面这些信息：



以前写入日志的数据块 Db，现在直接写到文件系统本身，避免了额外的写入；由于磁盘的大部分 I/O 流量都是数据，不把数据写两次就能大大减轻日志带来的 I/O 负担。不过，这一改动确实引出了一个有意思的问题：我们应该在什么时候把数据块写到磁盘上?

 © 2008–23, ARPACI-DUSSEAU

为了更好地理解这个问题，我们再来看看追加文件的那个例子。这次更新包括三个块：I[v2]、B[v2] 和 Db。前两个都是元数据，会先记入日志，再做检查点（checkpoint）；后一个只会向文件系统写入一次。我们应该什么时候把 Db 写到磁盘上？这有关系吗？

事实证明，对于只记元数据的日志来说，数据写入的顺序确实很重要。例如，如果我们在事务（包含 I[v2] 和 B[v2]）完成之后才把 Db 写到磁盘，会怎样？遗憾的是，这种做法有一个问题：文件系统是一致的，但 I[v2] 最终可能指向垃圾数据。具体来说，考虑 I[v2] 和 B[v2] 写入了、但 Db 没能写到磁盘的情况。接着文件系统会尝试恢复。由于 Db 不在日志里，文件系统会重放（replay）对 I[v2] 和 B[v2] 的写入，得到一个（从文件系统元数据的角度看）一致的文件系统。然而，I[v2] 会指向垃圾数据，也就是 Db 本该写入的那个位置上原来的内容。

为了确保不出现这种情况，有些文件系统（例如 Linux ext3）会在相关的元数据写到磁盘之前，先把（普通文件的）数据块写到磁盘。具体来说，协议如下：

1. **数据写入：** 把数据写到最终位置；等待完成（这一等待是可选的，详见下文）。
2. **日志元数据写入：** 把开始块（begin block）和元数据写入日志；等待这些写入完成。
3. **日志提交：** 把事务提交块（transaction commit block，包含 TxE）写入日志；等待写入完成；事务现在已**提交**，包括数据在内。
4. **检查点元数据：** 把元数据更新的内容写到它们在文件系统中的最终位置。
5. **释放：** 之后，在日志超级块（journal superblock）中把这个事务标记为空闲。

通过强制先写数据，文件系统就能保证指针永远不会指向垃圾。事实上，“先写被指向的对象，再写指向它的对象”这条规则是崩溃一致性（crash consistency）的核心，其他一些崩溃一致性方案对它的利用还要更进一步 [GP94]（详见下文）。

在大多数系统中，元数据日志（类似于 ext3 中的有序日志）比完整的数据日志（data journaling）更流行。例如，Windows NTFS 和 SGI 的 XFS 都使用某种形式的元数据日志（metadata journaling）。Linux ext3 让你可以在数据（data）、有序（ordered）和无序（unordered）三种模式中任选一种（在无序模式下，数据可以在任何时候写入）。所有这些模式都能保持元数据一致；它们的区别在于对数据的语义。

最后要注意，正如上面的协议中所指出的，在发出日志写入（第 2 步）之前强制等待数据写入完成（第 1 步），并不是正确性所必需的。具体来说，同时发出对数据、事务开始块（transaction begin block）和日志元数据的写入也完全没问题；唯一真正的要求是，第 1 步和第 2 步要在发出日志提交块（第 3 步）之前完成。

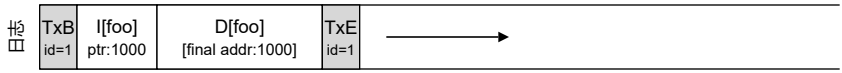
棘手的情况：块复用

还有一些有意思的边界情况会让日志变得更加棘手，因此值得讨论一下。其中有不少都和块复用有关；正如 Stephen Tweedie（ext3 背后的主要推动者之一）所说：

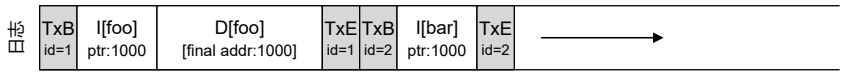
> “整个系统最可怕的部分是什么？……是删除文件。和删除有关的一切都很麻烦。和删除有关的一切……你会做噩梦，梦见块被删除、然后又被重新分配会发生什么。”[T00]

Tweedie 举的具体例子如下。假设你在使用某种形式的元数据日志（因此文件的数据块不记入日志）。假设你有一个叫 `foo` 的目录。用户往 `foo` 里加了一个目录项（比如创建了

一个文件），于是 foo 的内容（因为目录被视为元数据）被写入了日志；假设 foo 目录数据的位置是块 1000。于是日志里大概是这样的：



这时，用户删除了这个目录里的所有内容以及目录本身，块 1000 被释放出来，可以重新使用。最后，用户创建了一个新文件（比如叫 bar），它恰好复用了原来属于 foo 的那个块（1000）。bar 的 inode 和它的数据都提交到了磁盘；但要注意，由于使用的是元数据日志（metadata journaling），只有 bar 的 inode 提交到了日志中；文件 bar 写入块 1000 的新数据没有记入日志。



现在假设发生了崩溃，而所有这些信息都还在日志里。重放（replay）时，恢复过程只是简单地重放日志中的所有内容，包括对块 1000 中目录数据的写入；于是，重放（replay）会用旧的目录内容覆盖当前文件 bar 的用户数据！显然，这不是正确的恢复操作，用户读文件 bar 时肯定会大吃一惊。

这个问题有几种解决办法。例如，可以规定：在这些块的删除操作通过检查点（checkpoint）移出日志之前，绝不复用这些块。Linux ext3 的做法则是在日志中加入一种新的记录类型，叫作 **revoke record**。在上面的例子中，删除目录会导致一条 revoke record 被写入日志。重放（replay）日志时，系统先扫描这类 revoke record；任何已被撤销（revoke）的数据都不会被重放（replay），从而避免了上面提到的问题。

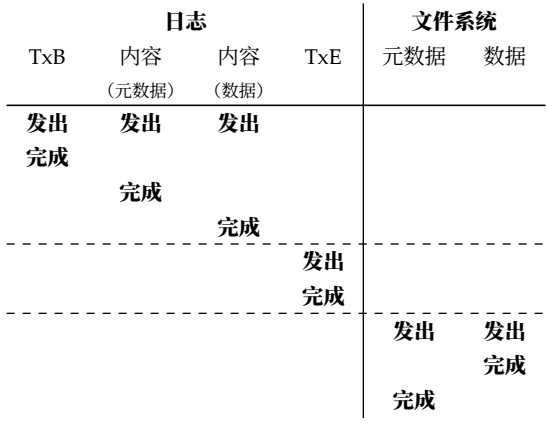


图 42.1：**数据日志的时间线**

 © 2008–23, ARPACI-DUSSEAU

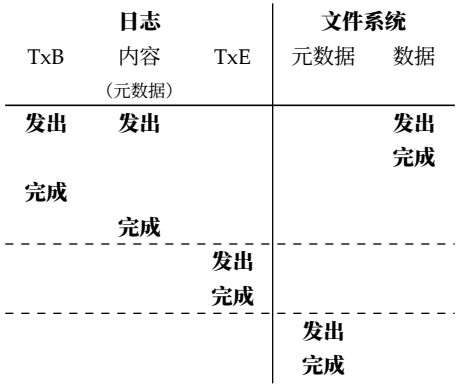


图 42.2：**元数据日志的时间线**

日志小结：时间线

在结束对日志的讨论之前，我们用时间线把讨论过的协议各总结一遍。图 42.1（第 13 页）展示的是对数据和元数据都记日志时的协议，图 42.2（第 14 页）展示的是只对元数据记日志时的协议。

在每张图中，时间向下递增，图中的每一行表示一次写入可以发出或可能完成的逻辑时间。例如，在数据日志（data journaling）协议中（图 42.1），事务开始块（TxB）的写入和事务内容的写入在逻辑上可以同时发出，因此可以按任意顺序完成；但是，对事务结束块（TxE）的写入，必须等前面这些写入完成之后才能发出。同样，对数据块和元数据块的检查点（checkpoint）写入，要等事务结束块（transaction end block）提交之后才能开始。水平虚线表示必须遵守写入顺序要求的地方。

元数据日志（metadata journaling）协议也有一张类似的时间线。注意，数据写入在逻辑上可以和事务开始块（transaction begin block）以及日志内容的写入同时发出；但是，它必须在事务结束块（transaction end block）发出之前发出并完成。

最后要注意，时间线中为每次写入标出的完成时间是任意的。在真实的系统中，完成时间由 I/O 子系统决定，它可能会为了提高性能而对写入重新排序。我们对顺序仅有的保证，就是为了协议的正确性而必须强制执行的那些（在图中用水平虚线表示）。

42.4 方案三：其他方法

到目前为止，我们介绍了保持文件系统元数据一致的两种方案：一种是基于 fsck 的“偷懒”方法，另一种是更主动的方法，叫作日志。然而，方法并不只有这两种。其中一种方法叫作软更新（Soft Updates）[GP94]，由 Ganger 和 Patt 提出。这种方法仔细地安排对文件系统的所有写入的顺序，确保磁盘上的结构永远不会处于不一致的状态。例如，通过在指向某个数据块的 inode 之前先把这个数据块写到磁盘，我们就能确保 inode 永远不会指向垃圾；对文件系统的所有结构，都可以推导出类似的规则。不过，实现软更新（soft updates）可能很有挑战性；上面描述的日志层在实现时只需要对文件系统的具体结构有比较少的了解，

而软更新（soft updates）则需要对每个文件系统数据结构都有细致入微的了解，因此会给系统增加相当多的复杂性。

另一种方法叫作**写时复制**（copy-on-write，没错，就是 **COW**），许多流行的文件系统都在使用它，包括 Sun 的 ZFS [B07]。这种技术从不原地覆盖文件或目录；而是把新的更新放到磁盘上以前没有使用过的位置。完成若干次更新之后，COW 文件系统会翻转文件系统的根结构，让它包含指向新更新的结构的指针。这样做使得保持文件系统一致变得很简单。在后面的章节讨论日志结构文件系统（LFS）时，我们会更多地了解这种技术；LFS 就是 COW 的一个早期例子。

还有一种方法是我们在威斯康星这里刚刚开发出来的。这种技术叫作 **backpointer-based consistency**（**BBC**），它不在写入之间强制规定任何顺序。为了实现一致性，系统中的每个块都会额外加上一个**反向指针**（back pointer）；例如，每个数据块都引用它所属的 inode。访问文件时，文件系统可以检查正向指针（例如 inode 或直接块中的地址）所指向的块是否反过来引用了它，以此判断这个文件是否一致。如果是，那么一切一定都已安全地写到了磁盘上，因此文件是一致的；如果不是，文件就是不一致的，并返回一个错误。通过给文件系统加上反向指针（back pointer），可以实现一种新形式的“偷懒”式崩溃一致性（crash consistency） [C+12]。

最后，我们还研究了一些技术，用来减少日志协议必须等待磁盘写入完成的次数。这种新方法叫作 **optimistic crash consistency** [C+13]，它利用一种推广形式的**事务校验和**（transaction checksum）[P+05]，尽可能多地向磁盘发出写入，并采用了另外几种技术，以便在出现不一致时将其检测出来。对于某些工作负载，这些乐观的技术能把性能提高一个数量级。然而，要真正发挥作用，需要一个稍有不同的磁盘接口 [C+13]。

42.5 小结

我们介绍了崩溃一致性问题（crash-consistency problem），并讨论了解决这个问题的各种方法。较老的方法是构建一个文件系统检查程序（file system checker），它能用，但在现代系统上恢复起来可能太慢了。因此，现在许多文件系统都使用日志。日志把恢复时间从 O(磁盘卷的大小) 减少到 O(日志的大小)，从而大大加快了崩溃重启后的恢复速度。正因如此，许多现代文件系统都使用日志。我们还看到，日志可以有许多不同的形式；最常用的是有序元数据日志（metadata journaling），它减少了写入日志的流量，同时仍然对文件系统元数据和用户数据都提供了合理的一致性保证。归根结底，对用户数据提供强有力的保证，可能是最重要的事情之一；说来也怪，正如最近的研究所表明的，这个领域仍然在不断发展 [P+14]。

参考文献

[B07] “ZFS: The Last Word in File Systems” by Jeff Bonwick and Bill Moore. Available online: http://www.ostep.org/Citations/zfs_last.pdf. *ZFS uses copy-on-write and journaling, actually, as in some cases, logging writes to disk will perform better.*

[C+12] “Consistency Without Ordering” by Vijay Chidambaram, Tushar Sharma, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. FAST ’12, San Jose, California. *A recent paper of ours about a new form of crash consistency based on back pointers. Read it for the exciting details!*

[C+13] “Optimistic Crash Consistency” by Vijay Chidambaram, Thanu S. Pillai, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau . SOSP ’13, Nemacolin Woodlands Resort, PA, November 2013. *Our work on a more optimistic and higher performance journaling protocol. For workloads that call* `fsync()` *a lot, performance can be greatly improved.*

[GP94] “Metadata Update Performance in File Systems” by Gregory R. Ganger and Yale N. Patt. OSDI ’94. *A clever paper about using careful ordering of writes as the main way to achieve consistency. Implemented later in BSD-based systems.*

[G+08] “SQCK: A Declarative File System Checker” by Haryadi S. Gunawi, Abhishek Rajimwale, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. OSDI ’08, San Diego, California. *Our own paper on a new and better way to build a file system checker using SQL queries. We also show some problems with the existing checker, finding numerous bugs and odd behaviors, a direct result of the complexity of* `fsck`.

[H87] “Reimplementing the Cedar File System Using Logging and Group Commit” by Robert Hagmann. SOSP ’87, Austin, Texas, November 1987. *The first work (that we know of) that applied write-ahead logging (a.k.a. journaling) to a file system.*

[M+13] “ffsck: The Fast File System Checker” by Ao Ma, Chris Dragga, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. FAST ’13, San Jose, California, February 2013. *A recent paper of ours detailing how to make fsck an order of magnitude faster. Some of the ideas have already been incorporated into the BSD file system checker [MK96] and are deployed today.*

[MK96] “Fsck – The UNIX File System Check Program” by Marshall Kirk McKusick and T. J. Kowalski. Revised in 1996. *Describes the first comprehensive file-system checking tool, the eponymous* `fsck`. *Written by some of the same people who brought you FFS.*

[MJLF84] “A Fast File System for UNIX” by Marshall K. McKusick, William N. Joy, Sam J. Leffler, Robert S. Fabry. ACM Transactions on Computing Systems, Volume 2:3, August 1984. *You already know enough about FFS, right? But come on, it is OK to re-reference important papers.*

[P+14] “All File Systems Are Not Created Equal: On the Complexity of Crafting Crash-Consistent Applications” by Thanumalayan Sankaranarayana Pillai, Vijay Chidambaram, Ramnatthan Alagappan, Samer Al-Kiswany, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. OSDI ’14, Broomfield, Colorado, October 2014. *A paper in which we study what file systems guarantee after crashes, and show that applications expect something different, leading to all sorts of interesting problems.*

[P+05] “IRON File Systems” by Vijayan Prabhakaran, Lakshmi N. Bairavasundaram, Nitin Agrawal, Haryadi S. Gunawi, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. SOSP ’05, Brighton, England, October 2005. *A paper mostly focused on studying how file systems react to disk failures. Towards the end, we introduce a transaction checksum to speed up logging, which was eventually adopted into Linux ext4.*

[PAA05] “Analysis and Evolution of Journaling File Systems” by Vijayan Prabhakaran, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. USENIX ’05, Anaheim, California, April 2005. *An early paper we wrote analyzing how journaling file systems work.*

[R+11] “Coerced Cache Eviction and Discreet-Mode Journaling” by Abhishek Rajimwale, Vijay Chidambaram, Deepak Ramamurthi, Andrea C. Arpaci-Dusseau, Remzi H. Arpaci-Dusseau. DSN ’11, Hong Kong, China, June 2011. *Our own paper on the problem of disks that buffer writes in a memory cache instead of forcing them to disk, even when explicitly told not to do that! Our solution to overcome this problem: if you want A to be written to disk before B, first write A, then send a lot of “dummy” writes to disk, hopefully causing A to be forced to disk to make room for them in the cache. A neat if impractical solution.*

[T98] “Journaling the Linux ext2fs File System” by Stephen C. Tweedie. The Fourth Annual Linux Expo, May 1998. *Tweedie did much of the heavy lifting in adding journaling to the Linux ext2 file system; the result, not surprisingly, is called ext3. Some nice design decisions include the strong focus on backwards compatibility, e.g., you can just add a journaling file to an existing ext2 file system and then mount it as an ext3 file system.*

 © 2008–23, ARPACI-DUSSEAU

[T00] “EXT3, Journaling Filesystem” by Stephen Tweedie. Talk at the Ottawa Linux Symposium, July 2000. olstrans.sourceforge.net/release/OLS2000-ext3/OLS2000-ext3.html *A transcript of a talk given by Tweedie on ext3.*

[T01] “The Linux ext2 File System” by Theodore Ts’o, June, 2001.. Available online here: http://e2fsprogs.sourceforge.net/ext2.html. *A simple Linux file system based on the ideas found in FFS. For a while it was quite heavily used; now it is really just in the kernel as an example of a simple file system.*

 © 2008–23, ARPACI-DUSSEAU

作业（模拟）

本节介绍 `fsck.py`，这是一个简单的模拟器，可以帮你更好地理解如何检测（并可能修复）文件系统损坏。关于如何运行这个模拟器，请参阅附带的 README。

问题

1. 首先，运行 `fsck.py -D`；这个选项会关闭所有损坏，因此你可以用它生成一个随机的文件系统，看看你能否判断出里面有哪些文件和目录。那就动手吧！用 `-p` 选项看看你是否答对了。把随机种子（`-s`）设成不同的值，比如 1、2 和 3，对几个不同的随机生成的文件系统试一试。
2. 现在，我们来引入一处损坏。先运行 `fsck.py -S 1`。你能看出引入了什么不一致吗？在真实的文件系统修复工具中，你会怎样修复它？用 `-c` 检查你是否答对了。
3. 把种子改成 `-S 3` 或 `-S 19`；你看到了什么不一致？用 `-c` 检查你的答案。这两种情况有什么不同？
4. 把种子改成 `-S 5`；你看到了什么不一致？自动修复这个问题会有多难？用 `-c` 检查你的答案。然后，用 `-S 38` 引入一个类似的不一致；这个更难检测吗？能检测出来吗？最后，用 `-S 642`；这个不一致能检测出来吗？如果能，你会怎样修复这个文件系统？
5. 把种子改成 `-S 6` 或 `-S 13`；你看到了什么不一致？用 `-c` 检查你的答案。这两种情况有什么区别？修复工具遇到这种情况时应该怎么做？
6. 把种子改成 `-S 9`；你看到了什么不一致？用 `-c` 检查你的答案。在这种情况下，检查修复工具应该相信哪一部分信息？
7. 把种子改成 `-S 15`；你看到了什么不一致？用 `-c` 检查你的答案。在这种情况下，修复工具能做什么？如果无法修复，会丢失多少数据？
8. 把种子改成 `-S 10`；你看到了什么不一致？用 `-c` 检查你的答案。这里的文件系统结构中有没有冗余（redundancy）信息可以帮助修复？
9. 把种子改成 `-S 16` 和 `-S 20`；你看到了什么不一致？用 `-c` 检查你的答案。修复工具应该怎样修复这个问题？

 © 2008–23, ARPACI-DUSSEAU