48

分布式系统

分布式系统（distributed system）改变了世界的面貌。你的 Web 浏览器连接到地球另一端的某台 Web 服务器时，它参与的就是一种看似简单的**客户端/服务器**（client/server）分布式系统。不过，你访问 Google 或 Facebook 这样的现代 Web 服务时，与你交互的并不只是一台机器；在幕后，这些复杂的服务由一大批（成千上万台）机器构成，它们相互协作，共同提供这个网站的服务。由此不难看出，研究分布式系统为什么这么有意思。这个主题甚至值得单独开一门课；这里我们只介绍其中几个主要话题。

构建分布式系统会遇到许多新的挑战。我们关注的主要挑战是**故障**（failure）：机器、磁盘、网络和软件都会时不时出故障，因为我们不知道（而且很可能永远都不会知道）怎样构建“完美”的组件和系统。然而，构建现代 Web 服务时，我们希望在客户端看来，它从不出故障。怎样才能做到这一点呢？

关键问题：
如何构建在组件出故障时仍能工作的系统
怎样用并非一直正常工作的部件，构建出一个能正常工作的系统？这个基本问题应该会让你想起我们在 RAID 存储阵列中讨论过的一些话题；不过，这里的问题往往更复杂，解决方案也是如此。

有意思的是，故障虽然是构建分布式系统的核心挑战，但它也带来了机遇。没错，机器会出故障；但一台机器出故障，并不意味着整个系统都必须跟着出故障。把一组机器组织起来，即使其中的组件经常出故障，我们也能构建出一个看起来很少出故障的系统。这正是分布式系统的美妙和价值所在，也是你在用的几乎每一个现代 Web 服务（包括 Google、Facebook 等）都建立在分布式系统之上的原因。

提示：通信本质上是不可靠的
几乎在任何情况下，都应该把通信看作一种从根本上不可靠的活动。比特损坏、链路和机器宕机或无法工作、缺少缓冲区（buffer）空间来容纳传入的数据包（packet），这些都会导致同一个结果：数据包有时到不了目的地。要在这样不可靠的网络之上构建可靠的服务，就必须考虑能够应对丢包（packet loss）的技术。

此外还有其他重要问题。系统**性能**（performance）往往至关重要；由于分布式系统靠网络连接在一起，系统设计者常常必须仔细考虑如何完成给定的任务，尽量减少发送的消息数，并让通信尽可能高效，做到低延迟、高带宽（bandwidth）。

最后，**安全**（security）也是必须考虑的问题。连接到远程站点时，如何确认对方确实是它自称的那一方，就成了核心问题。此外，确保第三方无法监视或篡改另外两方之间正在进行的通信，也是一项挑战。

在这篇介绍中，我们要讨论分布式系统中最基本的新问题：**通信**（communication）。也就是说，分布式系统中的机器应该如何彼此通信？我们会从最基本的原语（消息）讲起，再在它之上构建几个更高层的原语。如上所述，故障将是讨论的重点：通信层应该如何处理故障？

48.1 通信基础

现代网络的核心信条是：通信从根本上就是不可靠的。无论是在广域的互联网上，还是在 Infiniband 这样的局域高速网络中，数据包都经常会丢失、损坏，或者因为其他原因到不了目的地。

导致数据包丢失或损坏的原因多种多样。有时，传输过程中由于电气或其他类似问题，一些比特发生了翻转。有时，系统中的某个部件，比如网络链路、路由器，甚至远程主机，出于某种原因损坏了或者无法正常工作；网线也确实会被意外切断，至少偶尔如此。

然而，更根本的丢包原因，是网络交换机、路由器或端点内部的缓冲不足。具体来说，即使我们能保证所有链路都正常工作，系统中所有的组件（交换机、路由器、终端主机）都按预期正常运行，仍然可能丢包，原因如下。假设一个数据包到达一台路由器；为了处理这个数据包，必须把它放到路由器内部的某块内存里。如果同时有很多这样的数据包到达，路由器里的内存就可能容纳不下所有数据包。这时，路由器唯一的选择就是**丢弃**（drop）其中一个或多个数据包。终端主机上也会发生同样的情况：你向一台机器发送大量消息时，这台机器的资源很容易就会不堪重负，于是又会丢包。

所以说，丢包是网络中的基本问题。那么，该怎样应对丢包呢？

48.2 不可靠的通信层

一个简单的办法是：不去应对它。有些应用程序知道如何处理丢包，所以有时让它们直接用一个基本的、不可靠的消息层通信也很有用，这就是人们常说的**端到端原则**（end-to-end argument）的一个例子（见本章末尾的**补充**）。这种不可靠通信层的一个绝佳例子，就是如今几乎所有现代系统上都有的 **UDP/IP** 网络协议栈（networking stack）。要使用 UDP，进程（process）要通过**套接字**（sockets）API 创建一个**通信端点**（communication endpoint）；其他机器上（或者同一台机器上）的进程向这个进程发送 UDP **数据报**（datagram）。数据报就是一条大小有上限的定长消息。

图 48.1 和图 48.2 展示了一个构建在 UDP/IP 之上的简单客户端和服务器。客户端可以向服务器发送一条消息，服务器随后返回一条回复。只用这么一点代码，你就拥有了开始构建分布式系统所需的一切！

 © 2008–23, ARPACI-DUSSEAU

```
// 客户端代码
int main(int argc, char *argv[]) {
  int sd = UDP_Open(20000);
  struct sockaddr_in addrSnd, addrRcv;
  int rc = UDP_FillSockAddr(&addrSnd, "cs.wisc.edu", 10000);
  char message[BUFFER_SIZE];
  sprintf(message, "hello world");
  rc = UDP_Write(sd, &addrSnd, message, BUFFER_SIZE);
  if (rc > 0)
    int rc = UDP_Read(sd, &addrRcv, message, BUFFER_SIZE);
  return 0;
}

// 服务器代码
int main(int argc, char *argv[]) {
  int sd = UDP_Open(10000);
  assert(sd > -1);
  while (1) {
    struct sockaddr_in addr;
    char message[BUFFER_SIZE];
    int rc = UDP_Read(sd, &addr, message, BUFFER_SIZE);
    if (rc > 0) {
      char reply[BUFFER_SIZE];
      sprintf(reply, "goodbye world");
      rc = UDP_Write(sd, &addr, reply, BUFFER_SIZE);
    }
  }
  return 0;
}
```

图 48.1：**UDP 示例代码（`client.c`、`server.c`）**

UDP 是不可靠通信层的一个很好的例子。使用 UDP 时，你会遇到数据包丢失（被丢弃）、因而到不了目的地的情况，而发送方永远不会知道包丢了。不过，这并不意味着 UDP 对任何故障都毫无防范。例如，UDP 带有一个**校验和**（checksum），用来检测某些形式的数据包损坏。

然而，许多应用程序只是想把数据发送到目的地，而不想操心丢包问题，所以我们还需要更多机制。具体来说，我们需要在不可靠的网络之上实现可靠的通信。

48.3 可靠的通信层

要构建可靠的通信层，我们需要一些新的机制和技术来处理丢包。我们来看一个简单的例子：客户端通过一条不可靠的连接向服务器发送一条消息。首先要回答的问题是：发送方怎么知道接收方确实收到了消息？

```
int UDP_Open(int port) {
  int sd;
  if ((sd = socket(AF_INET, SOCK_DGRAM, 0)) == -1)
    return -1;
  struct sockaddr_in myaddr;
  bzero(&myaddr, sizeof(myaddr));
  myaddr.sin_family      = AF_INET;
  myaddr.sin_port        = htons(port);
  myaddr.sin_addr.s_addr = INADDR_ANY;
  if (bind(sd, (struct sockaddr *) &myaddr,
           sizeof(myaddr)) == -1) {
    close(sd);
    return -1;
  }
  return sd;
}

int UDP_FillSockAddr(struct sockaddr_in *addr,
                     char *hostname, int port) {
  bzero(addr, sizeof(struct sockaddr_in));
  addr->sin_family = AF_INET;          // 主机字节序
  addr->sin_port   = htons(port);      // 网络字节序
  struct in_addr *in_addr;
  struct hostent *host_entry;
  if ((host_entry = gethostbyname(hostname)) == NULL)
    return -1;
  in_addr = (struct in_addr *) host_entry->h_addr;
  addr->sin_addr = *in_addr;
  return 0;
}

int UDP_Write(int sd, struct sockaddr_in *addr,
              char *buffer, int n) {
  int addr_len = sizeof(struct sockaddr_in);
  return sendto(sd, buffer, n, 0, (struct sockaddr *)
                addr, addr_len);
}

int UDP_Read(int sd, struct sockaddr_in *addr,
             char *buffer, int n) {
  int len = sizeof(struct sockaddr_in);
  return recvfrom(sd, buffer, n, 0, (struct sockaddr *)
                  addr, (socklen_t *) &len);
}
```

图 48.2: **一个简单的 UDP 库（`udp.c`）**

 © 2008–23, ARPACI-DUSSEAU

提示：用校验和保证完整性

在现代系统中，校验和（checksum）是一种常用的方法，可以快速、有效地检测数据损坏。最简单的校验和就是加法：把一块数据的所有字节加起来；当然，人们还设计出了许多更复杂的校验和，包括基本的循环冗余校验（CRC）、Fletcher 校验和（Fletcher checksum）等等 [MK09]。

在网络中，校验和的用法如下。从一台机器向另一台机器发送消息之前，先对消息的字节计算一个校验和，然后把消息和校验和一起发往目的地。在目的地，接收方同样对收到的消息计算校验和；如果算出的校验和与发来的校验和一致，接收方就可以比较放心，认为数据在传输过程中很可能没有损坏。

评价校验和可以从几个不同的角度入手。有效性是一个首要考虑：数据发生变化时，校验和会不会随之改变？校验和越强，数据的变化就越难逃过检测。性能是另一个重要标准：计算校验和的代价有多大？遗憾的是，有效性和性能常常相互矛盾：高质量的校验和，计算代价往往也高。生活，又一次不完美。

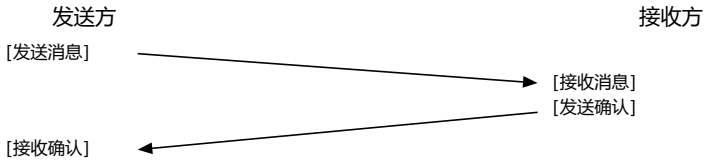


图 48.3：**消息加确认**

我们要用的技术叫作**确认**（acknowledgment），简称 **ack**。思路很简单：发送方向接收方发送一条消息；接收方随后回发一条简短的消息，确认自己收到了。图 48.3 描绘了这个过程。

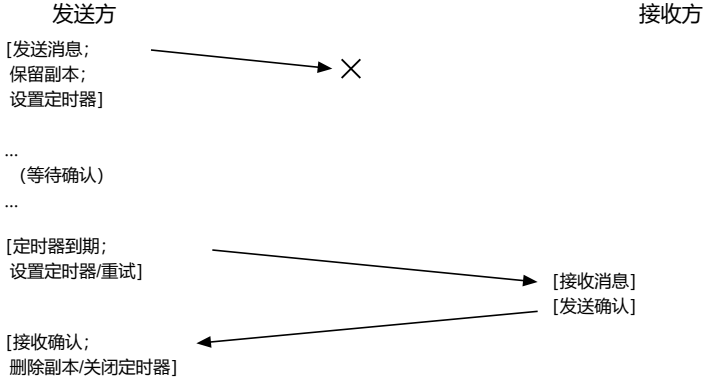


图 48.4：**消息加确认：请求丢失**

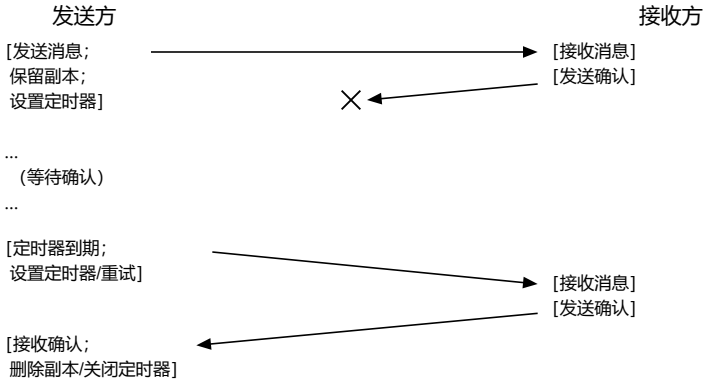


图 48.5：**消息加确认：回复丢失**

发送方收到这条消息的确认后，就可以确信接收方确实收到了原来的消息。可是，如果发送方没有收到确认，它该怎么办？

为了处理这种情况，我们还需要一个机制，叫作**超时**（timeout）。发送方发送消息时，会设置一个定时器，让它在一段时间后到期。如果在这段时间内没有收到确认，发送方就断定消息已经丢失，然后**重试**（retry）发送，把同一条消息再发一遍，希望这次能送达。为了让这种方法奏效，发送方必须保留一份消息副本，以备需要再次发送。超时和重试结合在一起，有人就把这种方法叫作**超时/重试**（timeout/retry）；搞网络的那帮人可真聪明，不是吗？图 48.4 给出了一个例子。

遗憾的是，这种形式的超时/重试还不够。图 48.5 给出了一个可能引发麻烦的丢包例子。在这个例子中，丢失的不是原来的消息，而是确认。从发送方的角度看，情况似乎是一样的：没有收到确认，因此应该超时并重试。但从接收方的角度看，情况就大不相同了：同一条消息被收到了两次！虽然有些情况下这样也没关系，但一般来说是不行的；想象一下，你下载一个文件时，下载内容里重复出现了多余的数据包，会发生什么。因此，要实现可靠的消息层，通常还得保证接收方对每条消息都**恰好接收一次**（exactly once）。

为了让接收方能够检测出重复传输的消息，发送方必须给每条消息加上唯一的标识，接收方也需要某种办法来记录自己是否已经见过每条消息。接收方发现重复传输时，只是确认这条消息，但（关键在于）不把它交给接收数据的应用程序。这样，发送方收到了确认，而消息又不会被接收两次，从而保持了上面说的恰好一次语义（exactly-once semantics）。

检测重复消息的办法有很多。例如，发送方可以为每条消息生成一个唯一的 ID；接收方可以记录它见过的每一个 ID。这种方法可行，但代价高得令人望而却步，因为要记录所有 ID，需要无限多的内存。

有一种更简单的机制能解决这个问题，而且几乎不占内存，叫作 **sequence counter**。使用 sequence counter 时，发送方和接收方先约定一个计数器的起始值（例如 1），双方各自维护这个计数器。每发送一条消息，就把计数器的当前值随消息一起发出去；这个计数器值（N）就充当这条消息的 ID。消息发出之后，发送方把计数器的值加一（变成 $N+1$）。

 © 2008–23, ARPACI-DUSSEAU

提示：设置超时值要小心

从上面的讨论中你大概也能猜到，用超时重发消息时，超时值（timeout value）设得对不对是个关键问题。超时值设得太小，发送方就会做无谓的重发，浪费发送方的 CPU 时间和网络资源。超时值设得太大，发送方要等很久才重发，它感受到的性能也会因此下降。因此，对单个客户端和服务器来说，“合适”的超时值应该刚好够发现丢包，不能再长。然而，正如我们在后面的章节中会看到的，分布式系统中往往不止一个客户端和一个服务器。在许多客户端向同一台服务器发送消息的场景中，服务器端的丢包可能意味着服务器已经过载。如果是这样，客户端也许应该换一种自适应的方式重试；例如，第一次超时之后，客户端可以把超时值调大一些，也许调到原来的两倍。这种**指数退避**（exponential back-off）方案由早期的 Aloha 网络首创，后来又被早期的以太网采用 [A70]，可以避免过多的重发把资源压垮。健壮的系统都会尽力避免这类过载。

接收方把自己的计数器值当作来自该发送方的下一条消息的预期 ID。如果收到的消息的 ID（N）与接收方的计数器值（同样是 N）相等，接收方就确认这条消息，并把它向上交给应用程序；在这种情况下，接收方断定这是第一次收到这条消息。然后，接收方把计数器加一（变成 $N+1$），等待下一条消息。

如果确认丢失了，发送方会超时并重发消息 N。这一次，接收方的计数器值更大（$N+1$），于是接收方知道自己已经收到过这条消息。它照样确认这条消息，但不把它向上交给应用程序。就这样，用 sequence counter 这种简单的方式就能避免重复。

最常用的可靠通信层叫作 **TCP/IP**，简称 **TCP**。TCP 比上面描述的要复杂得多，包括处理网络拥塞（network congestion）的机制 [VJ88]、多个未完成的请求，以及数以百计的其他小调整和优化。如果你好奇，可以去多读一些相关资料；更好的办法是去上一门网络课程，把这些内容学扎实。

48.4 通信抽象

有了基本的消息层，我们接下来讨论本章的下一个问题：构建分布式系统时，应该使用什么样的通信抽象（communication abstraction）？

多年来，系统研究界提出了许多方法。其中一类工作把操作系统的抽象（abstraction）拿过来，扩展到分布式环境中运行。例如，**分布式共享内存**（distributed shared memory，**DSM**）系统让不同机器上的进程能够共享一个很大的虚拟地址空间（virtual address space）[LH89]。这种抽象把分布式计算变成了看起来像多线程（multi-threaded）应用程序的东西；唯一的区别是，这些线程（thread）运行在不同的机器上，而不是同一台机器的不同处理器上。

大多数 DSM 系统都建立在操作系统的虚拟内存（virtual memory）系统之上。在一台机器上访问某一页（page）时，可能出现两种情况。第一种（最好的）情况是，这一页已经在本机上，于是数据很快就能取到。第二种情况是，这一页目前在其他某台机器上。这时会发生缺页异常（page fault），缺页异常处理程序（page-fault handler）向其他某台机器发送消息，取回这一页，把它装入发出请求的进程的页表（page table），然后继续执行。

 © 2008–23, ARPACI-DUSSEAU

由于种种原因，这种方法如今并没有得到广泛使用。DSM 最大的问题在于它如何处理故障。例如，设想一台机器出了故障，这台机器上的页会怎么样？如果分布式计算的数据结构（data structure）分散在整个地址空间（address space）中呢？在这种情况下，这些数据结构的一部分会突然变得不可用。地址空间的一部分消失了，要应对这样的故障是很难的；想象一个链表（linked list），其中某个“next”指针指向了地址空间中已经不存在的那部分。天哪！

另一个问题是性能。人们写代码时，通常假设访问内存的代价很低。在 DSM 系统中，有些访问代价很低，但另一些会引发缺页异常，需要代价高昂地从远程机器取数据。因此，这类 DSM 系统的程序员必须非常小心地组织计算，让它几乎不需要任何通信，而这在很大程度上违背了采用这种方法的初衷。虽然这个领域有过大量研究，但实际影响甚微；如今没有人用 DSM 构建可靠的分布式系统。

48.5 远程过程调用（RPC）

用操作系统的抽象构建分布式系统，结果并不理想；编程语言（PL）的抽象则要合理得多。最主流的抽象建立在**远程过程调用**（remote procedure call，简称 **RPC**）这一思想之上 [BN84][1]。

所有远程过程调用软件包都有一个简单的目标：让在远程机器上执行代码的过程，像调用本地函数一样简单直接。因此，在客户端看来，它发起一次过程调用（procedure call），过一段时间后，结果就返回了。服务器只需定义一些它想导出的例程，剩下的魔法都由 RPC 系统处理。RPC 系统一般由两部分组成：**存根生成器**（stub generator，有时也叫 **protocol compiler**）和**运行时库**（run-time library）。下面我们分别详细地看看这两部分。

存根生成器

存根生成器（stub generator）的任务很简单：把函数参数和结果自动打包成消息，省去手工打包的麻烦。这样做好处很多：从设计上就避免了手工编写这类代码时容易犯的简单错误；此外，存根编译器（stub compiler）或许还能优化这些代码，从而提高性能。

这种编译器的输入，就是服务器想导出给客户端的一组调用。从概念上讲，它可以简单到像这样：

```
interface {
  int func1(int arg1);
  int func2(int arg1, int arg2);
};
```

存根生成器（stub generator）拿到这样的接口后，会生成几段不同的代码。对客户端来说，会生成一个**客户端存根**（client stub），其中包含接口里列出的每一个函数；想使用这个 RPC 服务的客户端程序，只要链接这个客户端存根，并调用其中的函数，就能发起 RPC。

[1] 在现代编程语言中，我们也许会改称**远程方法调用**（remote method invocation，**RMI**），可是话说回来，谁会喜欢这些满是花哨对象的语言呢？

客户端存根中的每个函数，都会在内部完成执行远程过程调用所需的全部工作。在客户端看来，代码只是一次函数调用（例如，客户端调用 `func1(x)`）；而在内部，客户端存根中 `func1()` 的代码会做这些事：

- **创建消息缓冲区**。消息缓冲区（message buffer）通常就是一个有一定大小的连续字节数组。
- **把所需的信息打包进消息缓冲区**。这些信息包括要调用的函数的某种标识符，以及这个函数所需的全部参数（例如，在上面的例子中，`func1` 需要一个整数）。把这些信息全部放进一个连续缓冲区的过程，有时称为参数的**编组**（marshaling）或消息的**序列化**（serialization）。
- **把消息发送给目标 RPC 服务器**。与 RPC 服务器的通信，以及让通信正确运行所需的全部细节，都由 RPC 运行时库处理，下面会进一步介绍。
- **等待回复**。因为函数调用通常是**同步的**（synchronous），所以调用会等待它完成。
- **解包返回码和其他参数**。如果函数只返回一个返回码，这一步就很简单；但更复杂的函数可能返回更复杂的结果（例如一个列表），因此存根可能还需要把这些结果解包。这一步也叫**解组**（unmarshaling）或**反序列化**（deserialization）。
- **返回到调用者**。最后，从客户端存根返回到客户端代码中。

服务器端也会生成代码。服务器上的步骤如下：

- **解包消息**。这一步叫作**解组**（unmarshaling）或**反序列化**（deserialization）：从传入的消息中取出信息，得到函数标识符和参数。
- **调用实际的函数**。终于到了这一步！现在真正执行远程函数。RPC 运行时根据 ID 调用指定的函数，并传入所需的参数。
- **打包结果**。把返回的参数编组（marshal）回一个回复缓冲区（reply buffer）。
- **发送回复**。最后把回复发给调用者。

存根编译器（stub compiler）还要考虑另外几个重要问题。第一个是复杂参数，也就是说，如何打包并发送一个复杂的数据结构？例如，调用 `write()` 系统调用（system call）时，要传入三个参数：一个整数文件描述符（file descriptor）、一个指向缓冲区的指针，以及要写入的字节数（从指针处算起）。如果传给 RPC 软件包的是一个指针，它就得知道该怎样解释这个指针，并做出正确的处理。通常的做法有两种：一种是使用众所周知的类型（例如 RPC 编译器能够理解的 `buffer_t`，用来按给定大小传递数据块）；另一种是给数据结构加上更多注解信息，让编译器知道哪些字节需要序列化（serialize）。

另一个重要问题是服务器在并发（concurrency）方面如何组织。最简单的服务器只是在一个循环里等待请求，一次处理一个。但你大概已经猜到，这样做的效率可能极低：如果一次 RPC 调用阻塞了（例如在 I/O 上阻塞），服务器资源就被浪费了。因此，大多数服务器内部都是并发的。一种常见的组织方式是**线程池**（thread pool）：服务器启动时创建一组数量有限的线程；消息到达时，把它分派给其中一个工作线程（worker thread），由这个工作线程完成 RPC 调用的工作，最后返回回复；在此期间，主线程（main thread）继续接收其他请求，并可能把它们分派给其他工作线程。这样的组织方式让服务器内部可以并发执行（concurrent execution），从而提高了服务器的利用率（utilization）；常见的代价也随

之而来，主要是编程复杂度，因为 RPC 调用现在可能需要使用锁（lock）和其他同步原语（synchronization primitive）来确保正确运行。

运行时库

运行时库承担了 RPC 系统中的大部分繁重工作；大多数性能和可靠性（reliability）问题都在这里处理。下面讨论构建这样一个运行时层的几个主要挑战。

我们首先要克服的挑战之一，是如何找到远程服务。这个**命名**（naming）问题在分布式系统中很常见，在某种意义上也超出了我们当前讨论的范围。最简单的方法建立在现有的命名系统之上，例如当前互联网协议（internet protocol）提供的主机名和端口号（port number）。在这样的系统中，客户端必须知道运行所需 RPC 服务的机器的主机名或 IP 地址，以及该服务使用的端口号。端口号只是标识一台机器上某一项特定通信活动的方式，让一台机器能同时拥有多个通信通道。然后，协议族（protocol suite）必须提供一种机制，把数据包从系统中的任何其他机器路由到某个特定地址。关于命名的深入讨论，你得去别处找，例如去了解互联网上的 DNS 和名字解析（name resolution）；更好的办法是直接读 Saltzer 和 Kaashoek 那本书中精彩的一章 [SK09]。

客户端知道了某项远程服务该找哪台服务器之后，下一个问题是：RPC 应该建立在哪种传输层协议（transport-level protocol）之上？具体来说，RPC 系统应该使用 TCP/IP 这样的可靠协议（protocol），还是建立在 UDP/IP 这样的不可靠通信层之上？

乍一看，这个选择似乎很简单：我们显然希望请求能可靠地送达远程服务器，也显然希望能可靠地收到回复。所以，我们应该选择 TCP 这样的可靠传输协议，对吧？

遗憾的是，在可靠通信层之上构建 RPC，可能造成严重的性能浪费。回想一下上面讨论的可靠通信层是如何工作的：靠确认加上超时/重试。因此，客户端向服务器发送 RPC 请求时，服务器会回复一个确认，好让调用者知道请求已经收到。同样，服务器向客户端发送回复时，客户端也会确认，好让服务器知道回复已经收到。在可靠通信层之上构建请求/响应协议（request/response protocol），比如 RPC，就会多发送两条“额外”的消息。

因此，许多 RPC 软件包都建立在 UDP 这样的不可靠通信层之上。这样 RPC 层可以更高效，但提供可靠性的责任也就落到了 RPC 系统身上。RPC 层靠超时/重试和确认来达到所需的可靠性，做法和上面描述的差不多。借助某种形式的序号（sequence number），通信层可以保证每次 RPC 在没有故障时恰好执行一次（exactly once），在发生故障时至多执行一次（at most once）。

其他问题

RPC 运行时还必须处理其他一些问题。例如，如果一次远程调用需要很长时间才能完成，会怎么样？考虑到我们的超时机制，一个长时间运行的远程调用在客户端看来可能就像发生了故障，从而触发重试，所以这里需要小心处理。一种解决办法是：如果回复不能马上生成，接收方先给发送方发一个显式的确认，让客户端知道服务器已经收到了请求。此后，客户端可以定期询问服务器是否还在处理这个请求；如果服务器一直回答“是”，客户端就应该放心地继续等待（毕竟，过程调用有时确实要执行很久才能完成）。

 © 2008–23, ARPACI-DUSSEAU

补充：端到端原则

端到端原则（end-to-end argument）认为，在分层系统中，最高层（通常就是位于“端”上的应用程序）最终是唯一能够真正实现某些功能的地方。Saltzer 等人在他们那篇具有里程碑意义的论文 [SRC84] 中，用一个绝佳的例子论证了这一点：两台机器之间的可靠文件传输。如果你想把一个文件从机器 A 传到机器 B，并且确保最终落在 B 上的字节与从 A 出发时完全相同，你就必须对此做一次“端到端”的检查；更底层的可靠机制，例如网络或磁盘中的可靠机制，并不能提供这样的保证。

与之相对的做法，是给系统的较低层增加可靠性，试图以此解决可靠文件传输问题。例如，假设我们构建了一个可靠的通信协议（communication protocol），并用它来实现可靠的文件传输。这个通信协议（communication protocol）保证发送方发出的每一个字节都会被接收方按顺序收到，比如靠超时/重试、确认和序号（sequence number）来实现。可惜，光有这样的协议，并不能保证文件传输可靠：想象一下，在通信发生之前，字节就已经在发送方的内存中损坏了；或者接收方把数据写到磁盘时出了什么岔子。在这些情况下，即使字节在网络上被可靠地传送了，我们的文件传输最终也是不可靠的。要构建可靠的文件传输，就必须加入端到端的可靠性检查，例如，在整个传输完成之后，把接收方磁盘上的文件读回来，计算校验和，再和发送方文件的校验和比较。

这条准则的推论是，有时让较低层提供额外的功能，确实可以提高系统性能，或者以其他方式优化系统。因此，不应一概排斥在较低层设置这类机制，而应结合它在整个系统或应用中的最终用途，仔细权衡它的作用。

运行时还必须处理参数很大的过程调用，这些参数大到单个数据包都装不下。有些较低层的网络协议（network protocol）提供了这种发送方的**分片**（fragmentation，把较大的数据包分成一组较小的数据包）和接收方的**重组**（reassembly，把较小的部分重新组合成一个较大的逻辑整体）；如果没有，RPC 运行时可能就得自己实现这种功能。详情请参阅 Birrell 和 Nelson 的论文 [BN84]。

许多系统都要处理的一个问题是**字节序**（byte ordering）。你可能知道，有些机器按所谓的**大端**（big endian）顺序存储数值，另一些则使用**小端**（little endian）顺序。大端从最高有效位（most significant bit）到最低有效位（least significant bit）依次存储（比如一个整数的）各个字节，很像阿拉伯数字的写法；小端则正好相反。两种方式都是存储数值信息的有效方式；这里的问题是，字节序不同的机器之间如何通信。

RPC 软件包通常在消息格式中规定一种明确的字节序来解决这个问题。在 Sun 的 RPC 软件包中，**XDR**（**eXternal Data Representation**，外部数据表示）层提供了这一功能。如果收发消息的机器字节序与 XDR 一致，消息就照常发送和接收。但如果通信的机器字节序不同，消息中的每一项信息都必须转换。因此，字节序的差异会带来少许性能开销。

最后一个问题是，要不要把通信的异步（asynchronous）本质暴露给客户端，以便做一些性能优化。具体来说，典型的 RPC 是**同步**（synchronously）进行的，也就是说，客户端发起过程调用后，必须等过程调用返回才能继续执行。因为这种等待可能很长，而客户端也许还有其他工作可做，所以有些 RPC 软件包允许你**异步**（asynchronously）地发起 RPC。

 © 2008–23, ARPACI-DUSSEAU

发起异步 RPC 时，RPC 软件包发出请求后立即返回；客户端随后可以自由地做其他工作，比如调用其他 RPC 或做其他有用的计算。客户端到了某个时候会想看看异步 RPC 的结果；于是它再调用 RPC 层，让它等待未完成的 RPC 完成，然后就可以访问返回的参数了。

48.6 小结

我们介绍了分布式系统这个新主题，以及它的主要问题：如何应对已经司空见惯的故障。就像 Google 内部的说法：如果你只有一台台式机，故障很少见；可要是身处一个有成千上万台机器的数据中心，故障就无时无刻不在发生。任何分布式系统的关键，都在于你如何应对故障。

我们还看到，通信是一切分布式系统的核心。远程过程调用是对这种通信的一种常见抽象，它让客户端能够在服务器上发起远程调用；RPC 软件包处理所有繁琐的细节，包括超时/重试和确认，以提供一种与本地过程调用十分相像的服务。

要真正理解 RPC 软件包，最好的办法当然是亲自用一用。Sun 的 RPC 系统使用存根编译器（stub compiler）`rpcgen`，算是比较老的一个；Google 的 gRPC 和 Apache Thrift 则是同类系统的现代实现。挑一个试试，看看它们到底有什么了不起。

 © 2008–23, ARPACI-DUSSEAU

参考文献

[A70] "The ALOHA System — Another Alternative for Computer Communications" by Norman Abramson. The 1970 Fall Joint Computer Conference. *The ALOHA network pioneered some basic concepts in networking, including exponential back-off and retransmit, which formed the basis for communication in shared-bus Ethernet networks for years.*

[BN84] "Implementing Remote Procedure Calls" by Andrew D. Birrell, Bruce Jay Nelson. ACM TOCS, Volume 2:1, February 1984. *The foundational RPC system upon which all others build. Yes, another pioneering effort from our friends at Xerox PARC.*

[MK09] "The Effectiveness of Checksums for Embedded Control Networks" by Theresa C. Maxino and Philip J. Koopman. IEEE Transactions on Dependable and Secure Computing, 6:1, January '09. *A nice overview of basic checksum machinery and some performance and robustness comparisons between them.*

[LH89] "Memory Coherence in Shared Virtual Memory Systems" by Kai Li and Paul Hudak. ACM TOCS, 7:4, November 1989. *The introduction of software-based shared memory via virtual memory. An intriguing idea for sure, but not a lasting or good one in the end.*

[SK09] "Principles of Computer System Design" by Jerome H. Saltzer and M. Frans Kaashoek. Morgan-Kaufmann, 2009. *An excellent book on systems, and a must for every bookshelf. One of the few terrific discussions on naming we've seen.*

[SRC84] "End-To-End Arguments in System Design" by Jerome H. Saltzer, David P. Reed, David D. Clark. ACM TOCS, 2:4, November 1984. *A beautiful discussion of layering, abstraction, and where functionality must ultimately reside in computer systems.*

[VJ88] "Congestion Avoidance and Control" by Van Jacobson. SIGCOMM '88. *A pioneering paper on how clients should adjust to perceived network congestion; definitely one of the key pieces of technology underlying the Internet, and a must read for anyone serious about systems, and for Van Jacobson's relatives because well relatives should read all of your papers.*

 © 2008–23, ARPACI-DUSSEAU

作业（编程）

在这一部分，我们会写一些简单的通信代码，让你熟悉怎么做这件事。玩得开心！

问题

1. 用本章提供的代码，构建一个简单的基于 UDP 的服务器和客户端。服务器应该接收来自客户端的消息，并回复一个确认。第一次尝试时，不要加任何重传或健壮性机制（假设通信完全正常）。先在一台机器上运行测试，之后再在两台不同的机器上运行。
2. 把你的代码改造成一个**通信库**（communication library）。具体来说，设计你自己的 API，包括发送和接收调用，以及其他需要的 API 调用。改写你的客户端和服务器，让它们使用你的库，而不是直接调用原始的套接字接口。
3. 给你日渐成形的通信库（communication library）加上可靠通信，做法是**超时/重试**（timeout/retry）。具体来说，你的库应该为每条要发送的消息保留一份副本。发送时，应该启动一个定时器，以便记录消息发出后过了多长时间。在接收方，库应该**确认**（acknowledge）收到的消息。客户端在发送时应该**阻塞**（block），也就是说，它应该等到消息被确认之后才返回。它还应该不限次数地重试发送。消息的最大长度应该是用 UDP 能发送的最大单条消息的长度。最后，一定要高效地实现超时/重试：让调用者睡眠，直到确认到达或传输超时；不要自旋（spin）浪费 CPU！
4. 让你的库更高效、功能更丰富。首先，加入超大消息的传输。具体来说，尽管网络限制了消息的最大长度，你的库也应该能接收任意大小的消息，并把它从客户端传到服务器。客户端应该把这些大消息分成若干片段发给服务器；服务器端的库代码应该把收到的片段组装成连续的整体，再把这个大缓冲区交给等待中的服务器代码。
5. 再做一遍上面的事，但要做到高性能。不要一次只发一个片段，而应该快速地发送许多片段，从而让网络得到充分得多的利用。为此，要仔细标记传输中的每一个片段，确保接收方重组时不会把消息弄乱。
6. 最后一个实现上的挑战：按序交付的异步消息发送。也就是说，客户端应该能够反复调用发送函数，一条接一条地发送消息；接收方应该调用接收函数，可靠地按顺序收到每一条消息；发送方的许多消息应该可以同时在网络上传输。再加一个发送方的调用，让客户端可以等待所有未完成的消息都被确认。
7. 现在还有一个痛点：测量。测量你每种方法的带宽：在两台不同的机器之间能传输多少数据，速率是多少？再测量延迟：发送单个数据包并收到确认，要多久才能完成？最后，你的数据看起来合理吗？你原本的预期是什么？怎样才能更好地设定预期，以便判断是有问题，还是你的代码运行良好？

 © 2008–23, ARPACI-DUSSEAU